# PROJET DATAMINING M2 ISIFAR - AMSALHEM LE GAC

March 22, 2020

### 1 SVM sur des données fonctionnelles

5 -0.0408 ... 1.25 1.24 1.26 1.27

#### 1.1 Octane data

https://cran.r-project.org/web/packages/fds/fds.pdf section Octane

```
[95]: import numpy as np
     import pandas as pd
     import matplotlib.pyplot as plt
     from sklearn.neighbors import KNeighborsClassifier
     from sklearn.svm import SVC
     from sklearn.model selection import train test split, cross val score,
      from scipy.interpolate import UnivariateSpline
     %matplotlib inline
[77]: x = pd.read_csv('x.csv', squeeze=True, index_col=0)
     y = pd.read_csv('y.csv', index_col=0)
     raw_cible = pd.read_csv('cible.csv', squeeze=True, index_col=0)
     cible = raw_cible.copy()
     df = y.transpose()
     df.shape #60, 401)
     df.head()
[77]:
                  902
                                          908
                                                         912
          900
                          904
                                  906
                                                  910
                                                                 914
                                                                         916
     1 - 0.0502 - 0.0459 - 0.0422 - 0.0372 - 0.0333 - 0.0312 - 0.0300 - 0.0313 - 0.0342
     2 -0.0442 -0.0396 -0.0357 -0.0309 -0.0267 -0.0239 -0.0226 -0.0254 -0.0290
     3 -0.0469 -0.0413 -0.0370 -0.0315 -0.0265 -0.0233 -0.0214 -0.0250 -0.0293
     4 -0.0467 -0.0422 -0.0386 -0.0345 -0.0302 -0.0277 -0.0260 -0.0283 -0.0309
     5 -0.0509 -0.0451 -0.0410 -0.0364 -0.0327 -0.0315 -0.0314 -0.0346 -0.0378
          918
                   1682 1684 1686 1688
                                           1690
                                                1692
                                                      1694 1696 1698 1700
     1 -0.0360 ... 1.20 1.22 1.24 1.25
                                           1.25
                                                1.25
                                                      1.26 1.24 1.25 1.22
     2 -0.0327 ... 1.13 1.15 1.19 1.22
                                          1.25
                                                1.28
                                                      1.22 1.23 1.23 1.20
     3 -0.0339 ... 1.15 1.17 1.20 1.24
                                          1.26
                                                1.28
                                                     1.22 1.22 1.23 1.21
     4 -0.0340 ... 1.16 1.17 1.20 1.23
                                          1.26
                                                1.27
                                                      1.21 1.22 1.23 1.21
```

1.30 1.30 1.23 1.23 1.23 1.20

```
[5 rows x 401 columns]
```

On prend arbitrairement une valeur seuil : 87, pour se ramener à un problème de classification

```
[78]: seuil = 87
cible.loc[cible < seuil] = 0
cible.loc[cible >= seuil] = 1
```

## 1.2 Modèle de base : KNN, SVM sur les données brutes

L'idée est d'évaluer les performances pour les modèles de base sur les données brutes, pour ensuite comparer avec un SVM dont le noyau prend en compte la spécificité des données fonctionnelles.

KNN: mean Accuracy 0.81811 (500 CV)

SVM : mean Accuracy 0.62989 (500 CV)

```
[127]: #SVM repeated CV
#Kernel rbf
scores = []
for i in range(500):
    X_train, X_test, y_train, y_test = train_test_split(df, cible, train_size=0.
    →7)
    base_svm = SVC(kernel='rbf', gamma='scale', C=1)
    base_svm.fit(X_train, y_train)
    scores.append(base_svm.score(X_test, y_test))
print('SVM : mean Accuracy {:.5f} (500 CV)'.format(np.mean(scores)))
```

SVM : mean Accuracy 0.63211 (500 CV)

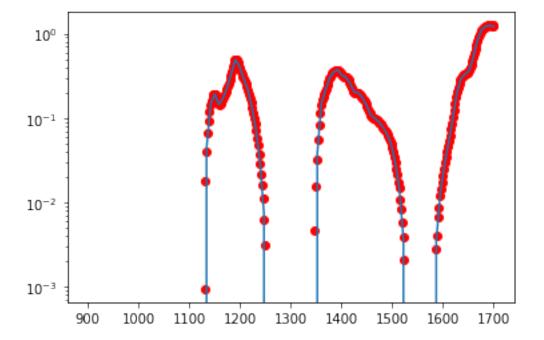
Mauvaises performances du SVM sur les données brutes

## 1.3 SVM après dérivées secondes

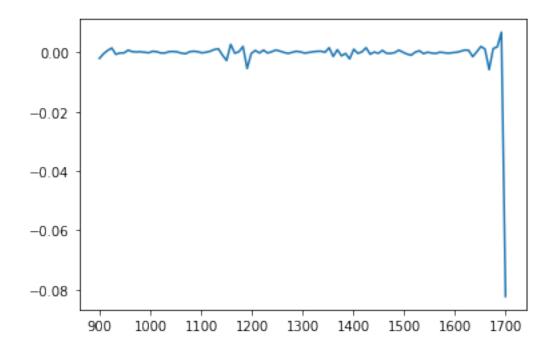
https://stackoverflow.com/questions/40226357/second-derivative-in-python-scipy-numpy-pand as a constraint of the const

#### EXEMPLE POUR UN INDIVIDU

```
[82]: #Exemple d'interpolation pour un individu
x_bis = np.array(x)
y_bis = np.array(y.iloc[:,0])
y_spl = UnivariateSpline(x_bis,y_bis,s=0,k=4)
plt.semilogy(x_bis,y_bis,'ro',label = 'data')
x_range = np.linspace(x_bis[0],x_bis[-1],100)
plt.semilogy(x_range,y_spl(x_range));
```



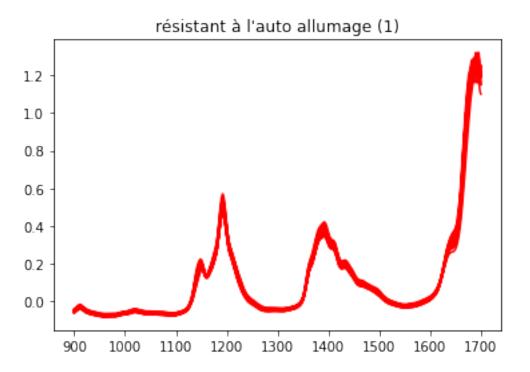
```
[83]: #Exemple d'une dérivée seconde pour un individu
y_spl_2d = y_spl.derivative(n=2)
plt.plot(x_range,y_spl_2d(x_range));
```



### POUR TOUS LES INDIVIDUS

```
[84]: idx_1 = cible.loc[cible == 1].index-1

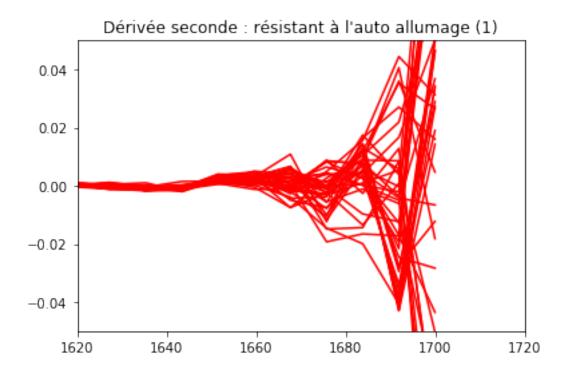
[85]: fig, ax = plt.subplots()
    for i in idx_1:
        plt.plot(x, df.iloc[i,:], 'r')
        ax.set_title('résistant à l\'auto allumage (1)');
```



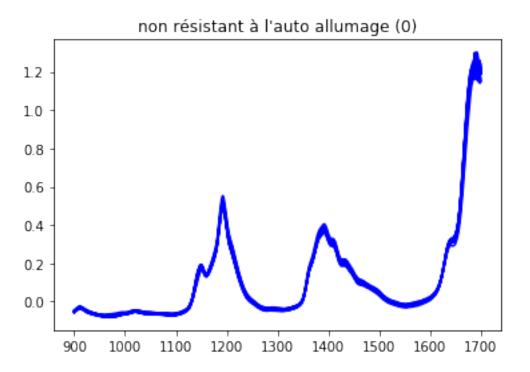
```
[86]: #On créer une fonction dérivée seconde
def sd_derivative(x, y, n=100):
    y_spl = UnivariateSpline(x,y,s=0,k=4)
    #x_range = np.linspace(x[0],x[-1],n)
    y_spl_2d = y_spl.derivative(n=2)
    return(y_spl_2d(x_range))

[87]: #On l'applique à tous les individus de la classe 1
    fig, ax = plt.subplots()

for i in idx_1:
    y_bis = np.array(y.iloc[:,i])
    plt.plot(x_range,sd_derivative(x_bis, y_bis), 'r')
    ax.set_title('Dérivée seconde : résistant à l\'auto allumage (1)')
    ax.set_xlim((1620, 1720))
    ax.set_ylim(-0.05, 0.05);
```

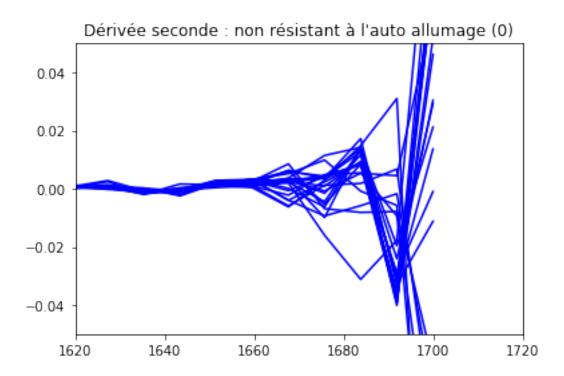


```
[93]: idx_0 = cible.loc[cible == 0].index-1
fig, ax = plt.subplots()
for i in idx_0:
    plt.plot(x, df.iloc[i,:], 'b')
ax.set_title('non résistant à l\'auto allumage (0)');
```



```
[89]: #On l'applique à tous les individus de la classe 0
fig, ax = plt.subplots()

for i in idx_0:
    y_bis = np.array(y.iloc[:,i])
    plt.plot(x_range,sd_derivative(x_bis, y_bis), 'b')
ax.set_title('Dérivée seconde : non résistant à l\'auto allumage (0)')
ax.set_xlim((1620, 1720))
ax.set_ylim(-0.05, 0.05);
```



[90]: #On reforme un dataframe

On obtient notre meilleur score!

SVM : mean Accuracy 0.64167 (500 CV), sur dérivées secondes

```
for i in range(500):
    X_train, X_test, y_train, y_test = train_test_split(df_sdD, cible,
    train_size=0.7)
    base_svm = SVC(kernel='rbf', gamma='scale', C=1)
    base_svm.fit(X_train, y_train)
    scores.append(base_svm.score(X_test, y_test))
print('SVM : mean Accuracy {:.5f} (500 CV), sur dérivées secondes'.format(np.
    →mean(scores)))
```

SVM : mean Accuracy 0.59722 (500 CV), sur dérivées secondes